Funciones de Aptitud

SECCIÓN 4

El corazón de todo algoritmo genético: cómo una función matemática convierte una solución candidata en un valor que guía la evolución hacia la respuesta óptima.

¿Qué es la Función de Aptitud?

Definición formal

Es una función matemática o lógica que toma un **individuo** (solución potencial) y devuelve un **valor numérico** que representa su calidad o desempeño dentro del espacio de búsqueda.

El "Oráculo" del sistema

Es la **única comunicación** entre el problema real y el algoritmo. Ella dicta qué soluciones son "buenas" y cuáles son "malas", sin revelar cómo mejorarlas.

Dependencia del problema

No existe una función de aptitud universal. Debe ser **diseñada específicamente** para cada problema de optimización, teniendo en cuenta los objetivos, restricciones y el dominio del problema.

> 💡 La función de aptitud es tan importante que una mala elección puede hacer que el algoritmo evolucione hacia soluciones incorrectas, sin importar qué tan bien esté implementado el resto.

El Rol de la Evaluación en el Ciclo Evolutivo

La evaluación de aptitud no ocurre una sola vez; se repite en cada generación, siendo el paso que conecta la genética con la selección natural.

1. Tomar el cromosoma

Se extrae la representación genética del individuo (genotipo) de la población actual.

2. Decodificar

Se transforma el genotipo en fenotipo: del código binario o real a la solución interpretable por el problema.

3. Evaluar la aptitud

El fenotipo se pasa por la función de aptitud y se obtiene un puntaje numérico que representa su calidad.

4. Asignar el puntaje

El valor calculado se asigna al individuo y sirve de base para la fase de **Selección**.

📍 La evaluación se ejecuta después de crear la población inicial y tras cada ciclo de cruce y mutación. Sin aptitud, no hay criterio de selección.

Maximización vs. Minimización

⬆️ Maximización

Buscamos el valor **más alto posible**. El algoritmo favorece individuos con mayor puntaje de aptitud.

- Ganancias económicas de un portafolio
- Eficiencia energética de un sistema
- Precisión de un modelo predictivo
- Cobertura de señal en una red

⬇️ Minimización

Buscamos el valor **más bajo posible**. Se busca reducir al mínimo el indicador objetivo.

- Costos de producción o logística
- Error cuadrático medio de un modelo
- Distancia recorrida en ruteo de vehículos
- Tiempo de ejecución de un proceso

La mayoría de los algoritmos genéticos están estandarizados para **maximizar**. Si el problema es de minimización, se aplica una transformación. Por ejemplo, para minimizar el error:

$$f(x) = \frac{1}{Error + 1}$$

Esta transformación convierte valores de error bajos (deseables) en valores de aptitud altos, manteniendo la lógica de maximización del algoritmo.

Características de una Buena Función de Aptitud

Para que un sistema de IA aprenda correctamente y converja hacia soluciones óptimas, la función de aptitud debe cumplir tres propiedades fundamentales.

🎯 Clara

Debe reflejar con **precisión el objetivo real** del problema. Una función que mide lo equivocado llevará al algoritmo a evolucionar soluciones irrelevantes o contraproducentes.

📡 Sensible

Pequeños cambios positivos en los genes deben reflejarse en **pequeños incrementos** en la aptitud. Esto crea un "gradiente evolutivo" que guía la búsqueda.

🔁 Consistente

La misma solución debe recibir siempre el **mismo puntaje** en entornos deterministas. La aleatoriedad en la evaluación introduce ruido que confunde al proceso selectivo.

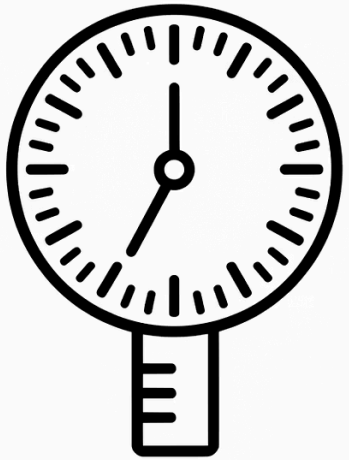

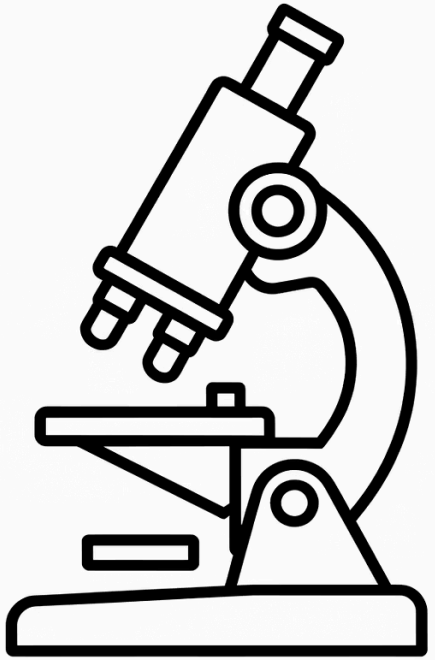

El Desafío de la Continuidad y los "Huecos"

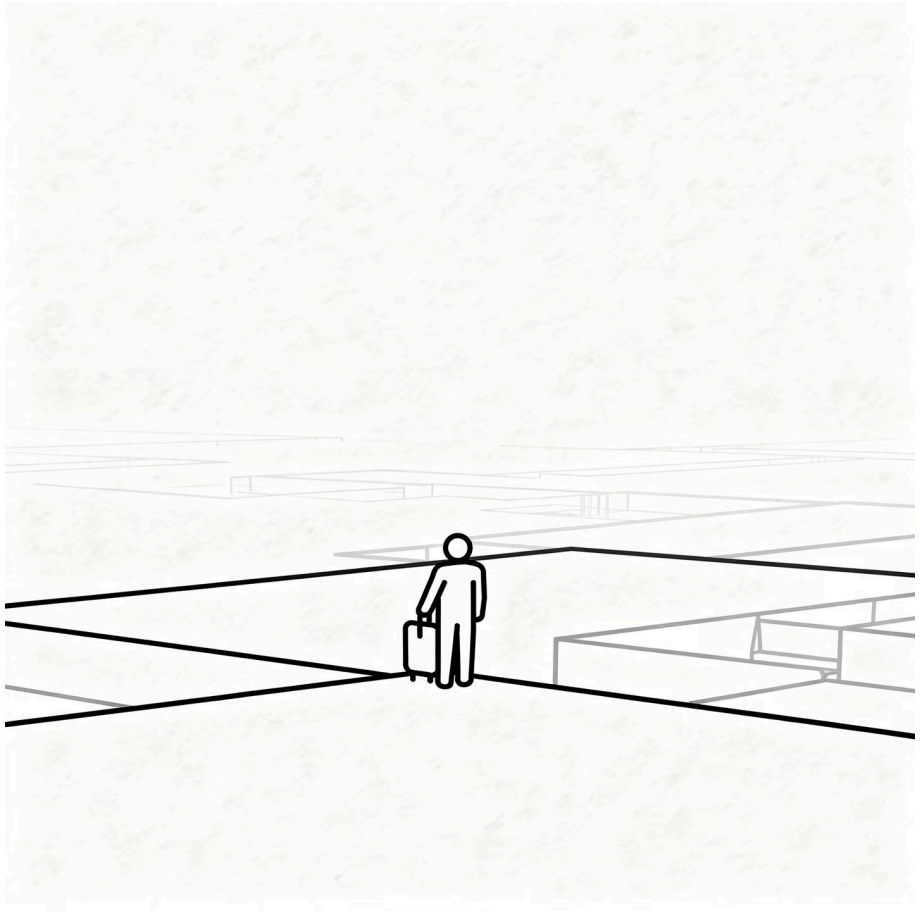

Funciones discontinuas: el problema de la "meseta"

Si la función devuelve el **mismo valor** para muchas soluciones diferentes, el algoritmo se pierde porque no puede distinguir cuál dirección mejora el resultado. La selección se vuelve arbitraria.

El gradiente evolutivo

La función debe proporcionar un **camino de mejora continuo**. Si solo devuelve valores binarios ("éxito" o "fracaso"), el algoritmo se convierte en una búsqueda aleatoria ineficiente.

> ⚠️ Una función que solo clasifica soluciones como "válida / inválida" elimina la información de gradiente y destruye la capacidad de aprendizaje incremental del algoritmo.

Costo Computacional de la Evaluación

OPTIMIZACIÓN DE RENDIMIENTO

La evaluación de aptitud es, con diferencia, el paso que más tiempo consume en un algoritmo genético. Entender su escala es crítico para diseñar sistemas eficientes.

100

Individuos por población

Tamaño típico de una población en un AG estándar.

500

Generaciones típicas

Número de ciclos evolutivos hasta la convergencia.

50K

Llamadas a la función

Total de evaluaciones: 100 × 500 = **50,000 llamadas** a la función de aptitud.

El cuello de botella

Si cada evaluación tarda 1 segundo (ej. un entrenamiento de red neuronal), 50,000 evaluaciones equivalen a más de **13 horas** de cómputo continuo.

Estrategia de aproximación

Se deben buscar representaciones matemáticas simplificadas o **modelos sustitutos (surrogate models)** cuando la evaluación real — como una simulación física — es computacionalmente costosa.

Manejo de Restricciones: Funciones de Penalización

El problema

El cruce y la mutación pueden generar soluciones **inválidas** que violan restricciones del negocio: pesos negativos, rutas imposibles, combinaciones prohibidas.

La solución: penalización

En lugar de eliminar al individuo, se le **reduce drásticamente su aptitud**. Sobrevive, pero con muy pocas probabilidades de reproducirse.

¿Por qué no simplemente eliminar al individuo inválido?

Eliminar soluciones inválidas puede reducir la **diversidad genética** de la población y causar convergencia prematura. La penalización mantiene material genético potencialmente útil en el acervo.

Tipos de penalización

Estática

Penalización fija por violar una restricción, independientemente del grado de violación.

Dinámica

La penalización aumenta con el tiempo, forzando soluciones válidas en las etapas finales de la evolución.

Escalado de la Aptitud (Scaling)

¿Por qué es necesario?

A medida que el algoritmo progresa, la población tiende a **homogeneizarse**. Las diferencias de aptitud entre individuos se vuelven mínimas, lo que reduce la presión selectiva y ralentiza la evolución.

La técnica de escalado

Se aplican **transformaciones matemáticas** sobre los valores originales de aptitud para exagerar las diferencias entre los mejores individuos, manteniendo así la competencia activa incluso en las etapas finales.

Ejemplos de transformaciones

- **Escalado lineal:** $f'(x) = a \cdot f(x) + b$
- **Escalado por potencias:** elevar la aptitud a un exponente mayor que 1
- **Escala logarítmica:** útil cuando los valores de aptitud tienen rangos muy amplios
- **Ranking:** ordenar individuos y asignar aptitud según posición

Efecto visual del escalado

Sin escalado, cuando la población converge, las diferencias de aptitud son tan pequeñas que la selección se vuelve casi aleatoria. Con escalado, incluso pequeñas mejoras generan ventajas selectivas significativas.

🔬 El escalado es especialmente crítico en las últimas generaciones, cuando la presión selectiva natural disminuye y el algoritmo necesita un "empujón" artificial para seguir mejorando.

Ejemplo Aplicado: Optimización de Pesos en IA

CASO PRÁCTICO

El contexto

Queremos ajustar los **pesos de una fórmula de predicción** para minimizar el error entre los valores predichos y los datos reales de entrenamiento.

Representación del cromosoma

Cada individuo es un vector de números reales que representa los pesos del modelo:

Cromosoma = $[w_1, w_2, w_3]$ → por ejemplo: [0.42, -0.17, 0.89]

Función de aptitud

Se calcula el error cuadrático medio (MSE) entre la predicción del modelo y los datos reales, y se transforma para maximizar:

$$f([w_1, w_2, w_3]) = \frac{1}{MSE + 1}$$

El proceso evolutivo

El algoritmo genético explora el espacio de combinaciones de pesos, evaluando cada vector con la función de aptitud y seleccionando los que producen menor error.

- Error alto → aptitud baja → baja probabilidad de reproducirse
- Error bajo → aptitud alta → alta probabilidad de transmitir genes
- Después de cientos de generaciones → pesos óptimos o near-óptimos

Meta final

Encontrar la combinación **$[w_1^*, w_2^*, w_3^*]$** que resulte en el fitness más alto, es decir, el menor error de predicción posible.

Evolución de la Aptitud en el Tiempo

Monitorear cómo cambia la aptitud a lo largo de las generaciones es fundamental para diagnosticar el comportamiento del algoritmo y detectar problemas como convergencia prematura o estancamiento.

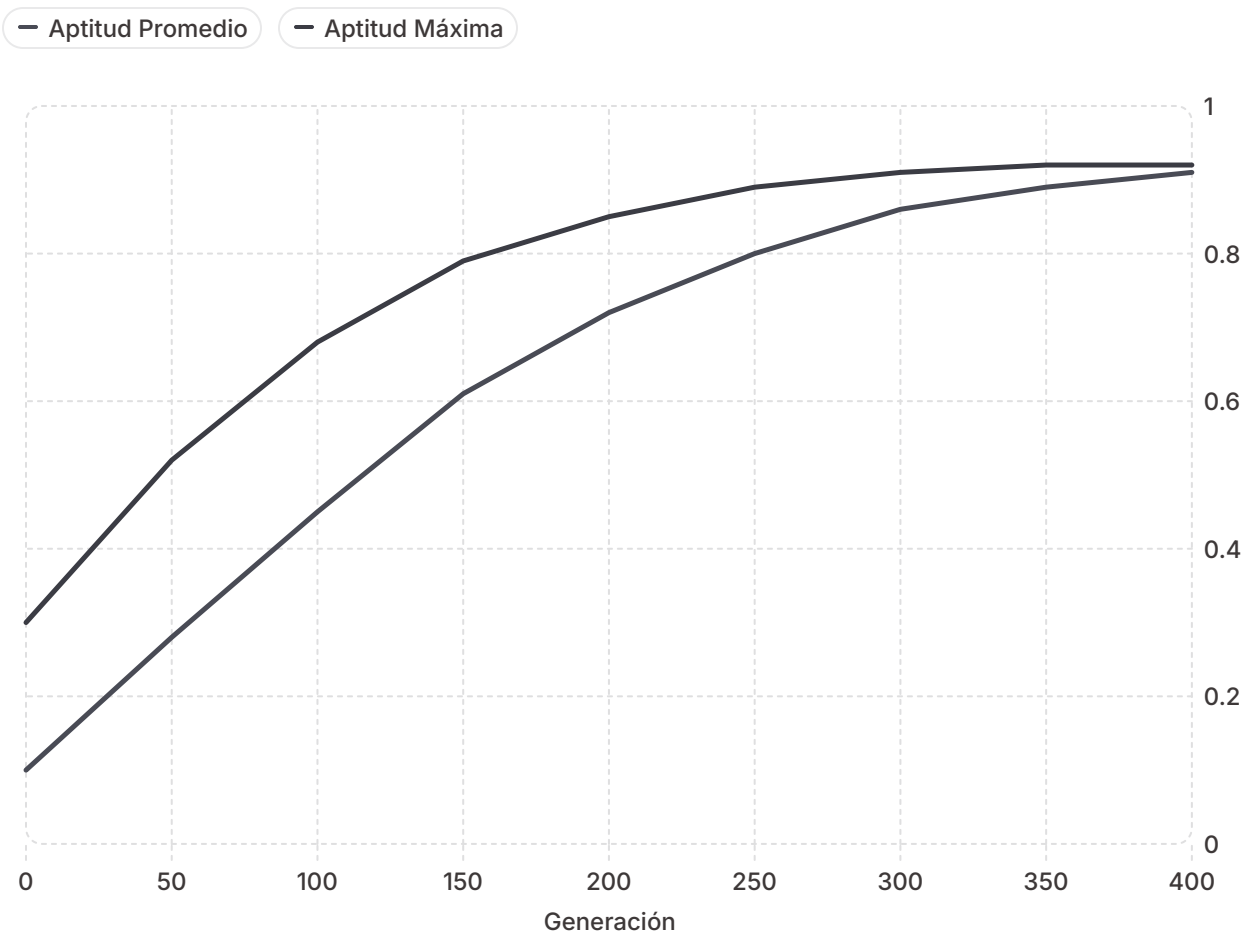

Aptitud Máxima

El mejor individuo de cada generación. Con **elitismo**, esta curva es siempre no decreciente: el mejor encontrado nunca empeora.

Aptitud Promedio

Indica la **salud y diversidad** de toda la población. Una brecha grande entre máximo y promedio sugiere que hay espacio de mejora.

Convergencia

Cuando la aptitud promedio se **acerca a la máxima**, el algoritmo ha encontrado una solución estable. La brecha se cierra y la evolución se ralentiza naturalmente.

Resumen: Claves de la Función de Aptitud

01

Es el oráculo del sistema

La única interfaz entre el algoritmo y el problema real. Su diseño determina hacia dónde evoluciona la población.

02

Debe ser sensible y continua

Proporcionar un gradiente de mejora. Funciones planas o binarias convierten la búsqueda en un proceso aleatorio.

03

El costo computacional es el cuello de botella

Con poblaciones grandes y muchas generaciones, la función se llama decenas de miles de veces. La eficiencia importa.

04

Las penalizaciones preservan la diversidad

En vez de eliminar soluciones inválidas, penalizarlas mantiene material genético que puede ser útil en combinación con otros individuos.

05

El escalado mantiene la presión selectiva

A medida que la población converge, el escalado evita que la selección se vuelva arbitraria y fuerza la mejora continua.