

Evolución del Perceptrón Multicapa

Análisis del desarrollo histórico, arquitectura interna y mecanismos de entrenamiento del aprendizaje automático moderno.

Raíces Biológicas (1943)

El primer intento formal por modelar el pensamiento humano fue el modelo de **McCulloch-Pitts**.


- Concebía a la neurona como un simple interruptor lógico binario.
- Recibía señales de entrada.
- Si la suma de señales superaba un límite rígido, la neurona se activaba.



“ El sistema carecía de una propiedad vital: la capacidad de aprender por sí mismo. Sus parámetros eran rígidos y debían ser configurados manualmente. ”

La limitación de la lógica preprogramada

La Revolución de Rosenblatt (1958)



Quince años después, Frank Rosenblatt dio un paso crítico al presentar el **Perceptrón**.

La innovación fundamental aquí fue la introducción matemática de los **pesos sinápticos (w)** y la capacidad intrínseca de entrenamiento.

El Paradigma del Aprendizaje

Reglas Fijas (Tradicional)

El diseñador humano establece estrictamente todas las condiciones lógicas (If/Else) necesarias para que el sistema opere ante un problema determinado.

Entrenamiento Supervisado

El Perceptrón utiliza un proceso iterativo de ensayo y error. Descubre las reglas **por sí mismo** basándose exclusivamente en los datos de entrenamiento proporcionados.

El Rol de los Pesos Sinápticos

W

Influencia

Cada entrada tiene un peso. Si es positivo y elevado, la característica es determinante; si es negativo, atenúa o inhibe la activación.

El Concepto de Sesgo (Bias)

b

Flexibilidad

Actúa como un peso independiente. Desplaza el umbral de activación para adaptarse a la distribución real de los datos en el espacio.

La Separabilidad Lineal



Hiperplano

El Perceptrón Simple es, por definición, un clasificador lineal. Su frontera de decisión siempre es recta.



Funcionamiento Ideal


Opera perfectamente siempre y cuando los datos se puedan dividir nítidamente con una línea en el plano.

El Problema XOR


Insuficiencia del Modelo

La mayoría de los problemas de la vida real no siguen una lógica lineal. El hito que demostró esto fue el problema lógico XOR.


Es matemáticamente imposible separar los puntos de activación de los de reposo mediante una **sola línea recta**.




(a)



(b)



(c)



(d)

“ Este descubrimiento provocó un estancamiento en la disciplina, ya que se hizo evidente que un solo nodo de procesamiento no podía resolver problemas de complejidad intermedia. ”

El Invierno de la Inteligencia Artificial



La Transición al MLP

El surgimiento del Perceptrón Multicapa

Arquitecturas Jerárquicas

Conexión Múltiple

Si una sola neurona no puede resolver un problema complejo, la conexión estructurada de muchas de ellas sí tiene la capacidad de hacerlo.

Intercalación

La solución fue intercalar "capas ocultas" entre la entrada de los datos y la salida final del sistema, multiplicando el poder de procesamiento.

Espacios de Abstracción



Patrones Básicos

En las primeras capas de la red, las neuronas se encargan de identificar formas, texturas o rasgos básicos.



Conceptos Complejos

Las capas profundas combinan esos patrones preliminares para formar conceptos altamente complejos y abstractos.

Rompiendo la Rigidez

-  Las capas jerárquicas no bastan por sí solas.
-  Se requiere el uso de **funciones de activación no lineales** en el interior de la red.
-  Estas funciones rompen la rigidez de las sumas matemáticas simples.
-  Permiten realizar una composición de funciones que modela geometrías complejas.

TouchDesigner

GLOSSY

Aproximador Universal

El MLP puede modelar prácticamente cualquier relación entre datos, por curva o compleja que sea la frontera, sentando las bases del Deep Learning moderno.

SURFACE



Make Art and Connect

Okamirufu Vizualizer
Tutorials



Flujo Unidireccional

2. Capas Ocultas

Transformaciones sucesivas y
no lineales.

1. Entrada

Captación de datos crudos del
exterior.


3. Salida

Consolidación de la predicción
abstracta.



La Capa de Entrada: El Receptor

IntelliPaat



Punto de Distribución

Es la interfaz con el mundo exterior. Actúa puramente como un sensor que capta el vector de características. Aquí **no se realizan** procesamiento matemáticos complejos ni se aplican funciones de activación.

Correspondencia Estricta

1:1

Dimensionalidad Rígida

Si el problema a resolver tiene diez variables de entrada relevantes, esta capa contará con exactamente diez neuronas transmisoras.

Las Capas Ocultas: Transformación

Profundidad

Permiten la existencia de múltiples niveles. Cada neurona recibe señales de la capa anterior, las multiplica por sus pesos y añade el sesgo.

Detección

Es el espacio donde el sistema logra detectar texturas, formas o las relaciones ocultas dentro del vector de características original.

“
Cuanto mayor es el número de
capas, más fino es el detalle
capturado, pero un exceso puede
llevar a que el modelo simplemente
memorice los datos en lugar de
generalizar.”

El Riesgo del Sobreajuste



La Capa de Salida

El Mecanismo de Decisión Final

Consolidación de Resultados

-  Encargada de entregar la respuesta definitiva del sistema.
-  A diferencia de las capas ocultas, su estructura está dictada rígidamente por el objetivo del modelo.
-  Consolida todo el procesamiento previo abstracto para emitir una conclusión útil.
-  Es la etapa que define la "personalidad" del sistema frente al usuario final.

Equilibrio en el Diseño de Redes

Subajuste (Underfitting)

Ocurre cuando el diseño físico de la red es demasiado simple (pocas neuronas/capas) para captar la realidad y complejidad del problema.

Sobreajuste (Overfitting)

Surge cuando el sistema es demasiado complejo. Pierde plasticidad, memoriza el ruido estadístico de los datos y pierde su capacidad de generalizar.

Dimensionamiento de la Salida

Tipo de Problema	Cantidad de Nodos	Naturaleza del Resultado
Clasificación Binaria	1 Neurona	Pertenece o no a una categoría específica.
Regresión Continua	1 Neurona	Entrega un valor numérico en escala continua.
Clasificación Multiclase	Múltiples Neuronas	Tantos nodos como categorías posibles existan.

“ La función de activación es el componente que otorga 'capacidad de juicio' a la neurona, transformando la suma ponderada en una señal de salida. ”

Introduciendo la No Linealidad

Funciones en Capas Ocultas: ReLU



El Estándar Actual

La Unidad Lineal Rectificada (ReLU) es la preferida en la industria por su simplicidad matemática y alta eficiencia computacional.



Filtro Positivo

Si el valor de entrada es positivo, se transmite íntegramente; si es negativo, se convierte instantáneamente en cero.

Variante: Leaky ReLU



Neuronas Inactivas


ReLU puro puede causar que algunas neuronas mueran al recibir siempre valores negativos, anulando el flujo del aprendizaje.



Paso Fraccionario

Leaky ReLU soluciona esto permitiendo el paso de una minúscula fracción de la señal negativa, manteniendo la neurona viva.

Salida: Clasificación Binaria



Función Sigmoide

Se utiliza exclusivamente cuando el sistema debe decidir entre dos opciones.

Comprime cualquier nivel de excitación interna de la red en un rango estricto entre **0 y 1**, lo que es ideal para expresar probabilidades (ej. $0.9 = 90\%$ de certeza).

Salida: Clasificación Multiclase

-  Utiliza la función **Softmax** para discriminar entre tres o más opciones excluyentes.
-  A diferencia de otras, Softmax observa la salida de *todas* las neuronas de la capa final simultáneamente.
-  Normaliza las salidas asegurando que la suma de todas sea exactamente igual a 1 (100%).
-  Opera bajo la regla de "el ganador se lleva todo", eligiendo la categoría con la probabilidad más alta.

Salida: Sistemas de Regresión

Función Lineal

El enfoque está en la precisión continua. Se utiliza una función lineal (o ninguna) para que la predicción pueda tomar absolutamente cualquier valor numérico (positivo o negativo).

Función Softplus


Utilizada cuando el problema exige que el resultado numérico sea estrictamente positivo (como la edad o el precio), asegurando una transición matemática suave por encima de cero.



Algoritmo de Backpropagation

El mecanismo de aprendizaje a través del error

La Ignorancia Inicial




La Función de Pérdida

Midiendo la Distancia

Una vez obtenida la predicción errónea, el sistema debe medir qué tan lejos está del valor real deseado.

La Función de Pérdida (Loss Function) cuantifica este error, devolviendo un valor único que representa la "responsabilidad" total de la red.

A Deep Dive into Gradient Descent Algorithms



Backward Pass: Reparto de Culpas



Distribución

El núcleo del algoritmo: toma el error calculado en la salida y lo propaga hacia atrás, hasta la primera capa.



Regla de la Cadena

Calcula derivadas para determinar matemáticamente cuánto contribuyó cada conexión (peso) individual al fallo total.


Descenso del Gradiente

Conocida la dirección del error, el sistema aplica la actualización de parámetros.

Si la función de pérdida fuera una montaña, el objetivo es llegar al valle más bajo donde el error es mínimo.

El gradiente le indica a la red hacia dónde se encuentra la pendiente más pronunciada hacia abajo.

A Deep Dive into Gradient Descent Algorithms



Tasa de Aprendizaje (Learning Rate)

Tasa Muy Alta

Los saltos de ajuste son grandes. El modelo intenta aprender muy rápido, pero corre el riesgo de "rebotar" en las paredes del valle y nunca alcanzar el punto de error mínimo.

Tasa Muy Baja

Los ajustes son diminutos. El proceso de convergencia será extremadamente lento e ineficiente, aunque altamente preciso al descender.

Calidad de Datos: El Combustible



Las redes son calculadoras de promedios ponderados; la entrada debe ser estrictamente numérica.



Normalización: Todas las entradas deben estar en una misma escala (ej. entre 0 y 1).




Evita el sesgo de magnitud: Impide que valores grandes (como un Salario) anulen matemáticamente a valores pequeños (como la Edad).

Volumen y Transformación

Concepto	Aplicación Práctica
Codificación (One-Hot)	Transforma variables categóricas ("Color", "Ciudad") en vectores numéricos legibles para la red.
Regla del 10x (Cantidad)	Empíricamente se requieren 10 veces más ejemplos de datos que conexiones/pesos posea el modelo.
Representatividad	El conjunto de entrenamiento debe ser una muestra fiel de la realidad global, sin sesgos demográficos.


Gestión de Épocas y Parada Temprana



Punto de Inflexión (Early Stopping)

Error de Entrenamiento (Siguiendo bajando) vs Error de Validación (Sube al memorizar ruido)

Caso: Evaluación Crediticia



Problema: Clasificación Binaria (Aprobar o Rechazar).

Input: 7 neuronas (Variables normalizadas + estado laboral codificado).

Ocultas: Embudo de 8 a 4 neuronas, usando función ReLU.

Output: 1 neurona, función Sigmoide. Si arroja > 0.85 , hay 85% de confianza de pago.

Monitoreo: Uso de datos de validación con "Paciencia" para detener la época antes de sobreajustar.

Image Sources




https://i.etsystatic.com/6098140/r/il/31528c/6271105526/il_570xN.6271105526_pye8.jpg

Source: www.etsy.com




https://news.cornell.edu/sites/default/files/styles/story_thumbnail_lg/public/2019-09/0925_rosenblatt_main.jpg?itok=Ji3fHBi6

Source: news.cornell.edu



https://www.mdpi.com/photonics/photonics-08-00392/article_deploy/html/images/photonics-08-00392-g004-550.jpg

Source: www.mdpi.com




<https://intellipaat.com/blog/wp-content/uploads/2018/08/Image-2.jpg>

Source: intellipaat.com



<https://img.favpng.com/20/10/18/monotonic-function-mathematics-graph-of-a-function-sigmoid-function-png-favpng-TsJmiDts4ZVxERAZQ0HcJRqm.jpg>


Source: favpng.com



https://miro.medium.com/1*BQiE-ObItO6KtOdbtrIPUw.png

Source: medium.com

Image Sources



https://www.mdpi.com/make/make-06-00085/article_deploy/html/images/make-06-00085-g001-550.jpg

Source: www.mdpi.com



<https://i.ytimg.com/vi/07o5RHCDI0M/maxresdefault.jpg>

Source: www.youtube.com